

# Raspoznavanje Materijala na Temelju Zvuka Uslijed Trenja

Marko Srpak

Zavod za elektroničke sustave i obradbu informacija  
Sveučilište u Zagrebu Fakultet elektrotehnike i računarstva  
Zagreb, Hrvatska  
[marko.srpak@fer.hr](mailto:marko.srpak@fer.hr)

Antun Hemetek

Zavod za elektroničke sustave i obradbu informacija  
Sveučilište u Zagrebu Fakultet elektrotehnike i računarstva  
Zagreb, Hrvatska  
[antun.hemetek@fer.hr](mailto:antun.hemetek@fer.hr)

**Sažetak**—Ljudi mogu čuti kada čaša padne na pod i detektirati je li čaša bila staklena, metalna ili plastična. Isto tako mogu prepoznati kada čuju grebanje je li riječ o drvenoj površini, metalnoj ili nekoj drugoj. Prepoznavanje materijala na temelju zvuka ljudi vrše automatski na temelju iskustva. Ovaj rad bavi se raspoznavanju materijala na temelju zvuka pomoću računalne (digitalne) obrade signala. Ova tematika je interesantna u područjima robotike i inteligentnih sustava kada postojeći sustavi kamera ili osjetilnih elemenata ne mogu dovoljno dobro procijeniti materijal nekog predmeta. Ideja je da zvuk također sadrži informaciju o materijalu i cilj ovog rada je istražiti na koji način je već postignuto ovo te osmisliti vlastitu metodu i algoritam raspoznavanja i evaluirati njegovu točnost.

**Ključne riječi**—raspoznavanje materijala, gustoća spektra snage, analiza zvuka, digitalna obrada signala

## I. UVOD

Naprednija živa bića koja posjeduju osjetilo sluha imaju urođenu karakteristiku prepoznavanja materijala iz zvučnog signala. To im je svojstvo popraćeno osjetilom sluha podarila evolucija. Taj signal može biti prouzrokovan padom predmeta s visine, tapkanjem jednog predmeta u drugi ili kontinuiranim trenjem između dva objekta. Istraživanja su pokazala da ljudi, a analogno i ostala naprednija živa bića, posjeduju dio u mozgu koji isključivo služi za raspoznavanje o kojim materijalima je riječ. Konkretno, kod ljudi, mozak enkodira bogata, ali šumovita fizička svojstva objekata i osnovne zakone fizičke interakcije između objekata. Postoji centar u ljudskom mozgu za shvaćanje i raspoznavanje fizike između tih objekata.[1]

Cilj ovog seminara je stvoriti algoritam raspoznavanja materijala sličan onom koji je ljudima urođen. Način raspoznavanja uzoraka, za razliku od onog prirodnog, ograničen je na raspoznavanje na temelju zvuka nastalog trenjem između dva objekta. U daljnjem tekstu ovo će se nazivati „zvuk trenja“. Ti objekti mogu biti od istog ili različitog materijala, ali je bitno da sva mjerenja budu obavljena između jednog stalnog objekta poznatog materijala i drugog nepoznatog materijala. Nakon što snimanja konstantnih zvučnih uzoraka od 5 različitih materijala (uključujući i zvuk tišine), proveden je algoritam raspoznavanja koji je opisan u kasnijim poglavljima.

Konačno, cilj je vidjeti koliko je odabrana metoda efikasna i točna. Konkretno, odabrana je metoda usporedbe gustoće spektara snage (kraće spektar snage) svakog uzorka. Razrađeni su spektri snage svakog uzorka i potom su analizirane sličnosti.

## II. PREGLED PODRUČJA I PROBLEMATIKA

### A. Raspoznavanje materijala

Iako ljudi to rade automatski i bez razmišljanja, navesti računalno da pravilno klasificira o kojem je materijalu riječ nije jednostavno. Potrebno je napraviti neku vrstu korelaciju između snimljenih uzoraka različitih materijala i odrediti pri kojim vrijednostima je ta korelacija maksimalna – tada je riječ o prepoznatom materijalu iz predefinirane baze zvukova. Ovo je analogno metodi raspoznavanja uzorka metodom tapkanja po površini promatranog objekta [2][3], ali budući da se ovdje koristila metoda raspoznavanja duljih snimljenih uzoraka, razvijen je drugačiji algoritam. Taj je algoritam namijenjen čitanju vremenski duljih uzoraka.

Postojeći radovi na temu raspoznavanja materijala [2][3][11] bave se većinski temom razvoja algoritma strojnog učenja koji će raspoznavati snimljene uzorke. Osim toga ovi radovi gledaju način proizvodnje zvukova pomoću računalnog programa ili koristeći robota za tapkanje. Niti jedan od članaka ne objašnjava detaljno način analize signala, osim da se koristi brza Fourierova transformacija (FFT) i promatra spektar signala.

Niti jedan prijašnji rad ne fokusira se na upotrebu gustoće spektra snage kao polaznu točku za obradu signala.

Ovi radovi na dobar način predstavljaju način evaluacije sustava za raspoznavanje. Koriste matrice zabune, računanje mjere F1 i Kappa koeficijenta. Jedan od radova [2] postiže mjeru F1 od čak 0.87 što pokazuje veliki potencijal za ispravnost rada ovakvih sustava.

### B. Upotreba spektra snage

Spektar snage našao je primjene u različitim područjima. Srednja snaga slučajnog procesa i gustoća spektra snage dani su sljedećim formulama:[4]

$$P_{xx} = \lim_{T \rightarrow \infty} \frac{1}{2T} \int_{-T}^T E[X^2(t)] dt \quad (1)$$

$$S_{xx}(\omega) = \lim_{T \rightarrow \infty} \frac{1}{2T} E[|X_T(t)|^2] \quad (2)$$

Prilikom računanja spektralne snage na računalnim sustavima koriste se jednostavnije metode i aproksimacije. Na primjer, spektar snage moguće je dobiti Fourierovom transformacijom iz autokorelacijske funkcije[5]. Jedno od područja gdje je pronađena korist spektralne analize snage je u fiziologiji: pretpostavlja se da postoji velika količina informacija u spektru snage na fiziološkim slikama. Te informacije se potom mogu izvući i mogu prikazati model zdravstvenog stanja pacijenta.[6]

Još jedna primjena spektra snage je u analizi spektra snage svjetla. Tako se otkriva zastupljenost pojedinih elemenata u udaljenim nebeskim tijelima poput zvijezda.

Spektroskopija se također dijelom koristi i u forenzici makar ne kao spektar snage već maseni spektar.

Ideja ovog rada je iskoristiti spektar snage zvučnog signala za dobivanje informacije o materijalu koji je proizveo taj zvuk. Očekuje se da različiti materijali imaju veću zastupljenost nekih frekvencija od drugih, na primjer drvo stvara relativno niske tonove, dok metal stvara generalno više tonove (većih frekvencija).

### C. Evaluacija rezultata

Evaluacija rezultata je integralni dio eksperimenta koji treba jasno pokazati koliko je uspješan eksperiment. [7] Raspoznavanje materijala je diskretna odluka gdje se za primljeni uzorak zvuka trenja treba reći kojem materijalu on pripada (ili da li ne pripada niti jednom). Ovakve diskretne odluke česti su problem u području strojnog učenja i umjetne inteligencije koji kategoriziraju i prepoznaju uzorke. Iako ovaj rad ne koristi nikakav oblik strojnog učenja već direktnu usporedbu frekvencijskih spektara, postoje metode evaluacije koje se koriste u strojnom učenju, a mogu se primijeniti i u ovom radu. Objašnjena su dva oblika evaluacije koji se često koriste kao mjera uspješnosti algoritma strojnog učenja. Prvi oblik je mjera F1 koja pokazuje performanse binarnog odlučivanja [8], a drugi je Cohenov kappa koeficijent [9] koji mjeri pouzdanost procjenjivanja [10] (engl. *inter-rater reliability*).

**Mjera F1:** Kada je riječ o binarnom zaključivanju o rezultatima nekog predviđanja moguća su četiri slučaja [7].

- stvarno pozitivni, (TP engl. *true positive*) - predikcija je 1 i stvarno je 1
- lažno pozitivni, (FP engl. *false positive*) - predikcija je 1, a stvarno je 0
- lažno negativni (FN engl. *false negative*) - predikcija je 0, a stvarno je 1
- stvarno negativni (TN engl. *true negative*) - predikcija je 0 i stvarno je 0

Ovo se primjenjuje prilikom raspoznavanja tako da se gleda koliko je puta neki materijal prepoznat ispravno (TP), koliko puta je prepoznat, a da nije zapravo bio ispravan (FP), koliko puta nije prepoznat, a bio je ispravan materijal (FN) te koliko puta nije prepoznat, a da se stvarno nije radilo o tom materijalu (TN).

Ove četiri vrijednosti često se postavljaju u matricu zabune (engl. *confusion matrix*).

$$\begin{bmatrix} TP & FP \\ FN & TN \end{bmatrix} \quad (3)$$

Matrica zabune sažeto prikazuje broj podudaranja i nepodudaranja. Za sustave koji nemaju binarno prepoznavanje već koriste kategorije (poput različitih materijala) matrice zabune nisu 2x2 već imaju onoliko redaka i stupaca koliko imaju materijala.

Vezano uz ove parametre definiraju se točnost (engl. *accuracy*), preciznost (engl. *precision*), odziv (engl. *recall*), ispadanje (engl. *fall-out*) i specifičnost (engl. *specificity*) [7].

$$\text{preciznost} \dots P = \frac{TP}{TP+FP} \quad (4)$$

$$\text{odziv} \dots R = \frac{TP}{TP+FN} \quad (5)$$

Mjera F1 računa se kao harmonijska sredina preciznosti i odziva. Ovo osigurava da se velike razlike u preciznosti i odzivu jako kažnjavaju.

$$\text{mjera F1} \dots F = \frac{2}{\frac{1}{P} + \frac{1}{R}} \quad (6)$$

**Cohenov kappa koeficijent:** Kappa koeficijent je statistička mjera koja se koristi za procjenu međusobnog poklapanja između dva procjenitelja nad istim skupom podataka. Ova mjera uzima u obzir slučajnosti u ocjenama i pruža korisnu informaciju o stupnju suglasnosti između ta dva procjenitelja. Jedan način računanja Kappa koeficijenta je:

$$\kappa = \frac{P_O - P_e}{1 - P_e} \quad (7)$$

Gdje su  $P_O$  opaženi stupanj suglasnosti između procjenitelja, a  $P_e$  je očekivani. Vrijednosti koju koeficijent poprima je između -1 i 1. Vrijednost 0 predstavlja slučajni odabir, pozitivne vrijednosti ukazuju na korelaciju, dok negativne vrijednosti ukazuju na mjeru suglasnosti koja je još gora od potpuno nasumične suglasnosti. U ovom radu ne računa se Kappa zbog premalog broja snimljenih uzoraka.

## III. EKSPERIMENT I REZULTATI

Ova sekcija opisuje izvedbu provedenog eksperimenta za raspoznavanje materijala. Izmjereni uzorci zvuka obrađeni su i sakupljeni u repozitorij (program za pretprocesiranje). Opisana je izvedba algoritma za uspoređivanje uzoraka (program za raspoznavanje) te su na kraju komentirani rezultati i točnost razvijenog modela za raspoznavanje materijala (program za postprocesiranje).

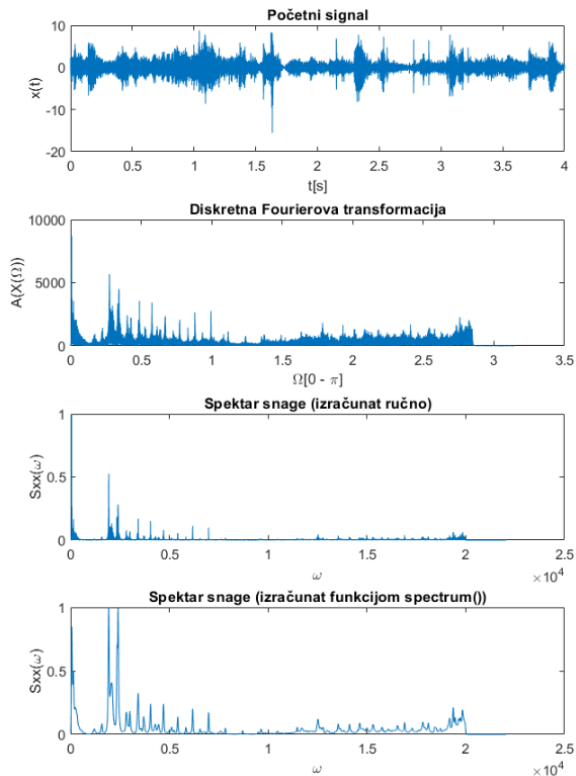
### A. Eksperimentalni postav

**Testni podaci:** Zvuk trenja javlja se kada se dva materijala trljaju jedan o drugog. U eksperimentu, zvuk trenja proizvodi se ravnalom koje kontinuirano struže po površini odabranog materijala. Odabirom istog ravnala za snimanje svakog uzorka, uklanja se ovisnost jednog materijala koje sudjeluje u trenju te se fokus pridaje mjerenom materijalu. Ravnalo je referentni materijal u eksperimentu. Testni podaci sastoje se od 15 snimaka (3 snimka za svaki od 5 testna materijala). Trajanje svake snimke je minimalno 4 sekunde, a snimanje je obavljeno s frekvencijom od 44100 Hz. Odabranih 5 materijala su drvo, čelik, keramika, plastika i pluto. Osim 15 snimaka materijala, snimljena je i tišina kako bi se kasnije kompenzirao pozadinski šum koji unosi specifičan mikrofon.

**Evaluacija rezultata:** Zbog malog broja uzoraka nije praktično dijeliti uzorke u grupu za treniranje i grupu za testiranje. Umjesto toga svaki uzorak je uspoređen sa svakim drugim uzorkom i promatrana je razina preklapanja. Ovakav način usporedbe očekuje da uzorak uspoređen sa samim sobom ima 100 % preklapanje, a s drugim uzorcima istog materijala očekuje se veće preklapanje nego s drugačijim materijalom. Uzorak s najvećim preklapanjem (osim samog sebe) uzet je kao detektirani materijal. Za evaluaciju modela računa se postotak uzoraka koji su detektirali ispravan materijal te se također računa mjera F1 za svaki materijal i njen prosjek.

## B. Analiza signala - preprocesiranje

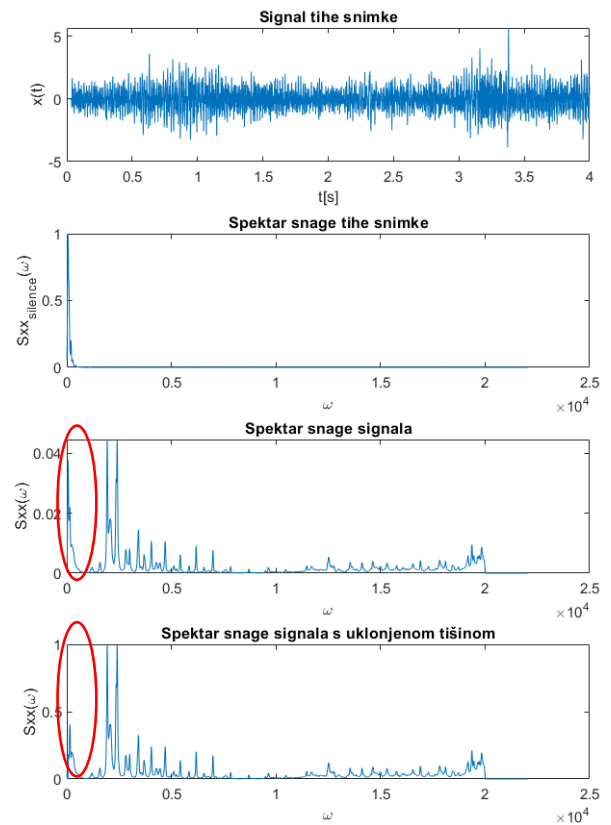
Za analizu signala razvijen je algoritam koji pred procesira podatke. Snimljeni uzorak najprije mora biti frekvencije 44100 Hz i izdvojene prve 4 sekunde uzorka. Analiza signala provedena je koristeći MatLab. Slika 1 pokazuje početni signal  $x$  (koji odgovara prvoj snimci čelika), diskretnu Fourierovu transformaciju signala, ručno izračunat spektar snage preko Fourierove transformacije autokorelacijske funkcije te spektar snage izračunat ugrađenom MatLab funkcijom `pspectrum()`. Ručni izračun traje oko minute zbog velikog broja uzoraka pri računanju autokorelacijske funkcije i ima veći šum od izračuna ugrađenom funkcijom koje je gotovo trenutno.



Slika 1. Signal za jedan uzorak čelika i njegovi spektri

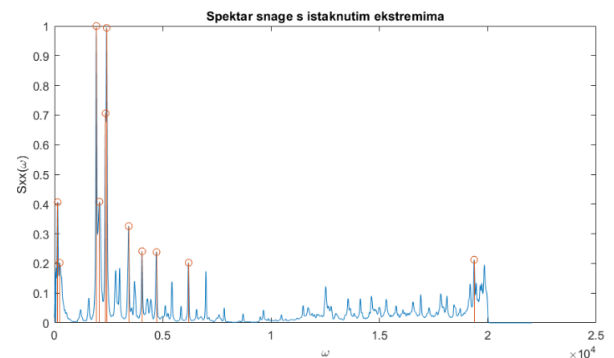
Nadalje se koristi spektar snage izračunat ugrađenom funkcijom kao najefikasniju opciju računanja spektra snage.

Sljedeći korak u obradi je ukloni šum koji mikrofoni detektira kad nema nikakvog zvuka. Ne koristi se neka od klasičnih metoda filtracije šuma jer je šum (koji proizvodi materijal) upravo ono što se nastoji izmjeriti. Za snimljeni „zvuk tišine“ je također određen spektar snage, te je skaliran na 1. Zatim je spektar snage pomnožen s  $(1 - \text{šum})$  kako bi se otklonile one komponente spektra snage koje su prisutne na svakoj snimci zbog „zvuka tišine“ te je i on skaliran na 1. Na slici 2 vidljivi su signal  $x$  koji je snimak tišine, spektar snage tihog snimka, spektar snage jedne snimke čelika te spektar snage čelika s uklonjenom komponentom tišine.



Slika 2. Signal tišine, spektar snage tišine i istaknuto uklanjanje komponente vezane uz tišinu

Nakon uklanjanja komponente tišine iz spektra snage, nalazimo najveće lokalne maksimume funkcije spektra snage koristeći MatLab funkciju `findpeaks()`. Moguće je zadati minimalnu traženu razinu signala (engl. *threshold*) te maksimalan broj maksimuma koji se želi izdvojiti. U radu je korištena minimalna razina  $th=0,2$ , te maksimalno  $N=20$  točaka. Na slici 3 je prikazan spektar snage jednog uzorka čelika i njegovi maksimumi pronađeni s ovim parametrima.



Slika 3. Spektar snage uzorka čelika s istaknutim maksimumima većim od 0.2

Informacija o frekvenciji svakog maksimuma te vrijednosti maksimuma sprema se kao MatLab-ova `.mat` datoteka tako da se informacija o lokalnim maksimumima spektra snage može brzo dohvatiti u programu za raspoznavanje.

## C. Usporedba uzoraka - raspoznavanje

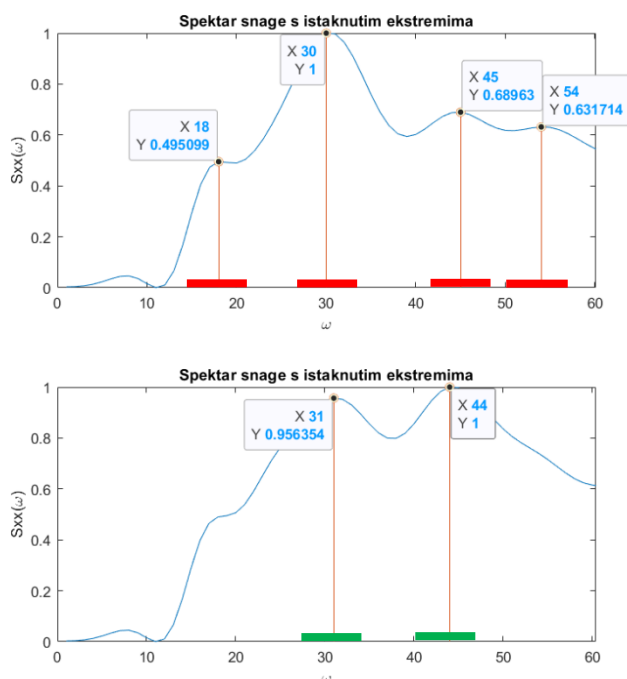
Zbog male količine uzoraka svaki se uzorak testira u odnosu na sve ostale. Prvo se za traženi uzorak nalaze ponovno lokalni maksimumi spektra snage. Uzete su

ponovno vrijednosti  $th=0,2$  te  $N=20$  uzoraka, ali moguće je odabrati i drugačije parametre od onih korištenih u pretprocesiranju podataka. Zatim se uspoređuje sa svakim poznatim uzorkom iz repozitorija. Jedna usporedba dva signala vrši se na sljedeći način:

1. Prolazi se kroz svaki maksimum traženog signala. Svakom maksimumu dodjeljuje se jednaka težinska vrijednost. Dakle ako uzorak ima  $N$  izdvojenih lokalnih maksimuma, svakome se pridjeljuje težina

$$T = \frac{1}{N} \quad (1)$$

2. Za svaki maksimum traži se pripadajući najbliži maksimum ne udaljen više od  $S$  uzoraka.  $S$  uzet u ovom radu je 4 uzorka i predstavlja mjeru dozvoljenog odstupanja. Na slici 4 je vidljivo je uvećano prikaz dva različita uzorka istog materijala te crvenom i zelenom bojom okolina od  $S=4$  uzorka za svaki od njih.



Slika 4. Dio spektra snage s maksimumima za dva različita uzorka pluta

Ako bi prvi signal bio testiran, a drugi iz repozitorija, reklo bi se da testirani signal ima vrh (lokalni maksimum) u  $X = 18$  i da nema pripadajućih vrhova na drugom signalu u blizini od 4 uzorka. Vrh u  $X=30$  ima pripadajući vrh u  $X=31$  koji je unutar crvenog područja. Isto tako vrh s  $X=45$  ima pripadajući vrh u  $X=44$ . Na kraju vrh u  $X=54$  također nema pripadajući vrh u drugom signalu.

Ako bi drugi signal bio testiran, a prvi iz repozitorija, rekli bi da se u zelenoj okolini vrha  $X=31$  nalazi vrh  $X=30$ , te da se u okolini vrha  $X=44$  nalazi pripadajući vrh  $X=45$ .

Unatoč razumijevanju da ova dva signala izgledaju slično, reklo bi se da prvi signal ima  $2/4$  frekvencije iste kao drugi, ali da drugi ima  $2/2$  frekvencije jednake kao prvi. Ovakva razlika u broju promatranih

frekvencija, uz činjenicu da težina  $T$  ovisi o broju maksimuma, dovodi do toga da signal A nije jednako sličan signalu B, kao što je signal B sličan signalu A.

3. Za svaki par pronađenih pripadnih vrhova računa se koeficijent preklapanja kao


$$C = \begin{cases} 0, & \text{ako nema pripadnog vrha} \\ \frac{y_1}{y_2} \cdot T, & \text{ako je } y_1 < y_2 \\ \frac{y_2}{y_1} \cdot T, & \text{ako je } y_1 > y_2 \end{cases} \quad (2)$$

Gdje su  $y_1$  i  $y_2$  veličine dva promatrana vrha. Ovo osigurava da je  $C \in [0, 1/T]$ .

4. Mjera sličnosti  $M$  dva signala definira se kao suma svih  $T$  koeficijenta preklapanja  $C$ . Ako se signali preklapaju u svim lokalnim maksimumima s jednakim iznosom, tada je iznos za svaki  $C=1/T$ , te je maksimalni mogući  $M=1=100\%$ . Ako se signali ne poklapaju u niti jednoj frekvenciji tada je  $M=0$ .
5. Računa se mjera sličnosti  $M$  za svaki par signala i sprema se u  $15 \times 15$  matricu. Na glavnoj dijagonali matrice nalaze se uzorci uspoređeni sa samim sobom koji uvijek (po definiciji mjere sličnosti) iznose 1. Matrica sličnosti sprema se kao varijabla u zasebnu .mat datoteku te postaje dostupna za postprocesiranje to jest evaluaciju.

#### D. Evaluacija rezultata – postprocesiranje

Eksperiment je proveden uz minimalnu razinu  $th=0.2$  i maksimalni broj vrhova  $N=20$  (pri pretprocesiranju i raspoznavanju) te dozvoljeno odstupanje  $S=4$  uzorka. Dobivana matrica sličnosti  $M$  prikazana je na slici 5.




Slika 5. Matrica sličnosti

Na matrici sličnosti ima 15 redaka koji odgovaraju svakom od 15 uzoraka. Materijali su redom drvo, čelik, keramika, plastika, pluto. Svaki materijal snimljen je u tri uzorka. Stupci imaju jednak redoslijed uzoraka kao i redci. U svakom retku je jedan materijal koji je testiran sa svim ostalim materijalima u svakom stupcu. Kao što je očekivano, na glavnoj dijagonali nalazi se uvijek sličnost  $M=1$  jer se uzorak uspoređuje sam sa sobom. Osim toga prepoznaju se

manje 3x3 matrice na glavnoj dijagonali (označene crveno) koje poprimaju generalno veće vrijednosti od ostatka matrice.

Detekcija se ostvaruje tako da se u svakom retku nađe najveća sličnost (osim uzorka na glavnoj dijagonali koji se i testirao) i to se uzima kao prepoznati materijal. Na slici 6 je prikazan najveći uzorak u svakom retku.



Slika 6. Raspoznati materijali

Žutom bojom su označeni uzorci koji su raspoznati, a svijetlo plavo su označeni uzorci istog materijala manjih matrica 3x3 radi vidljivosti. Jedini rezultat koji je pogrešno detektirao materijal je treći uzorak keramike koji je prepoznat kao drvo.

Najjednostavniji izračun mjere točnosti sustava jest da je ispravno prepoznato 14 od 15 uzoraka što je 93,3 %.

Za računanje mjere F1 prvo se prebroje sva TP, TN, FP i FN za svaki materijal, zatim se računaju preciznost i odziv svakog materijala te se na kraju računa mjera F1. Prosječna mjera F1 iznosi 0,94.

Tablica 1. Preciznost, odziv i mjera F1 svakog materijala

	Drvo	Čelik	Keramika	Plastika	Pluto	Prosjeck
TP	3	3	2	3	3	-
TN	11	12	11	12	12	-
FP	1	0	0	0	0	-
FN	0	0	1	0	0	-
Preciznost	0,75	1,00	1,00	1,00	1,00	<b>0,95</b>
Odziv	1,00	1,00	0,67	1,00	1,00	<b>0,93</b>
Mjera F1	0,86	1,00	0,80	1,00	1,00	<b>0,94</b>

#### IV. ZAKLJUČAK I BUDUĆI RAD

**Problematika:** U uvodu je predstavljena tema prepoznavanja materijala kao nešto što je živim bićima urođeno, a za računalo može predstavljati veliki izazov. Predstavljene su radovi na temu prepoznavanja materijala iz zvuka koji ne nude veliki uvid u analizu signala, ali na izvrstan način demonstriraju metode evaluacije algoritama za raspoznavanje. Predstavljeno je da korištenje gustoće spektra snage nalazi primjenu u nekim područjima i cilj ovog rada bio je testirati primjenu spektra snage u problemu raspoznavanja materijala. Predstavljene su mjere F1 i Kappa koeficijent kao popularna mjera testiranja rezultata.

**Eksperiment:** U provedenom eksperimentu mjerio se zvuk uslijed trenja za pet različitih materijala: drvo, čelik, keramiku, plastiku i pluto. Zvučni signal zatim je obrađen u spektar snage, uklonjena komponenta vezana uz šum tihe snimke te izdvojeni najveći lokalni maksimumi i spremljeni u repozitorij za daljnju obradu. Uspoređeni su spektri snage svakog sa svakim uzorkom tražeći pripadajuće maksimume u spektru snage. Izračunata je mjera sličnosti za svaki par uzoraka i spremljena u matricu sličnosti. Na kraju je provedeno raspoznavanje materijala na temelju mjera sličnosti.

Konačni rezultat pokazuje 14 od 15 ispravno prepoznatih uzoraka, te prosječnu mjerom F1 od **0,94**.

**Budući rad:** Provedeni eksperiment daje zadovoljavajuće rezultate i dokaz je da metoda usporedbe spektra snage pokazuje karakteristične frekvencije za materijale koji se mogu kvantificirati i kategorizirati. Unaprjeđenje algoritma i sustava je moguće u više aspekata. Primarni fokus daljnjeg rada zahtjeva prikupljanje većeg volumena mjerenih zvukova. 15 uzoraka je dovoljno za dokaz koncepta i uhođavanje algoritma, ali tek bi eksperiment s par stotina uzoraka ovakvo prepoznavanje učinio značajnim. Sljedeće unaprjeđenje, povezano s prethodnim bilo bi stvaranje sustava koji može primati snimke automatski i olakšati proces označavanja snimki. Veliko unaprjeđenje koje bi bilo moguće s većim brojem uzoraka je pronaći maksimume u frekvencijskoj domeni koji odgovaraju pojedinom materijalu. Tako bi se testiranje svodilo na provjeru s materijalima, a ne sa svim uzorcima svakog materijala što bi uvelike smanjilo vremensku kompleksnost algoritma. Manje modifikacije koje se trenutno mogu upravljati su odabir parametara  $th$ ,  $N$  i  $S$ . Viđeno je prilikom testiranja da postoje optimalni parametri koji su u ovom radu izabrani ručno, slobodnom procjenom i metodom pokušaja i pogreške. Nalaženje optimalnih parametara za najbolje raspoznavanje je zanimljiv problem s aspekta strojnog učenja koje bi ovakav sustav dodatno unaprijedio.

#### LITERATURA

- [1] Zhang, Zhoutong et al. "Shape and material from sound." Advances in Neural Information Processing Systems (NIPS 2017), 30 (2017). © 2017 Neural Information processing systems foundation, <https://dspace.mit.edu/bitstream/handle/1721.1/124779/6727-shape-and-material-from-sound.pdf?sequence=2&isAllowed=y>, pristupljeno: 22.1.2024.
- [2] K. Wang, H. Zeng, W. Feng, Q. Zheng and Y. Fang, "Surface Material Classification Based On Tapping Sound Characteristics," 2021 7th International Conference on Computer and Communications (ICCC), Chengdu, China, 2021, pp. 1762-1766, doi: 10.1109/ICCC54389.2021.9674472, <https://ieeexplore.ieee.org/document/9674472>, pristupljeno: 22.1.2024.
- [3] M. Dimiccoli, S. Patni, M. Hoffmann, F. Moreno-Noguer, Recognizing object surface material from impact sounds for robot manipulation, <https://digital.csic.es/bitstream/10261/306623/1/2619-Recognizing-object-surface-material-from-impact-sounds-for-robot-manipulation.pdf>, pristupljeno: 22.1.2024
- [4] Scott Millers & Donald Childers (2012). Probability and random processes. Academic Press. pp. 370–5, pristupljeno: 22.1.2024
- [5] S. Mokhtab, W. A. Poe, Chapter 14 - Process Control Fundamentals, Editor(s): Saeid Mokhtab, William A. Poe, Handbook of Natural Gas Transmission and Processing (Second Edition), Gulf Professional Publishing, 2012, Pages 473-509, ISBN 9780123869142, <https://doi.org/10.1016/B978-0-12-386914-2.00014-5>, pristupljeno: 22.1.2024
- [6] R. Gao. Interpreting the electrophysiological power spectrum. J Neurophysiol. 2016 Feb 1;115(2):628-30. doi: 10.1152/jn.00722.2015. Epub 2015 Aug 5. PMID: 26245320; PMCID: PMC4752306, <https://pubmed.ncbi.nlm.nih.gov/26245320/>, pristupljeno: 22.1.2024



- [7] Jan Šnajder, Strojno učenje, predavanja, Vrednovanje modela, Fakultet elektrotehnike i računarstva, Sveučilište u Zagrebu, 2023. pristupljeno: 22.1.2024
- [8] Hicks, S. A., Strümke, I., Thambawita, V., Hammou, M., Riegler, M. A., Halvorsen, P., & Parasa, S. (2022). On evaluation metrics for medical applications of artificial intelligence. *Scientific reports*, 12(1), 5979. <https://doi.org/10.1038/s41598-022-09954-8> pristupljeno: 22.1.2024
- [9] Cohen, J. (1960). A Coefficient of Agreement for Nominal Scales. *Educational and Psychological Measurement*, 20(1), 37-46. <https://doi.org/10.1177/001316446002000104> pristupljeno: 22.1.2024
- [10] Tang, Wan et al. "Kappa coefficient: a popular measure of rater agreement." *Shanghai archives of psychiatry* vol. 27,1 (2015): 62-7. doi:10.11919/j.issn.1002-0829.215010 pristupljeno: 22.1.2024
- [11] Zhang, Zhoutong et al. "Shape and material from sound." *Advances in Neural Information Processing Systems (NIPS 2017)*, 30 (2017). © 2017 Neural Information processing systems foundation

#### POPIS KORIŠTENIH PROGRAMA

1. read\_sound.m
2. preprocesing.m
3. recognition.m
4. postprocesing.m